Rubrics生成/改写调研

调研前的几个问题

- [ ] 怎么评价Rubric是好的，可用的，怎么让其他人信服这个Rubric（即使是专家标注是否有可信的行业标准）
- [ ] 是否按照**通用Rubrics**和**专业领域Rubrics**区分开来处理
- [ ] Rubric有哪些类型，我们可以采取什么类型的Rubric生成策略
- [ ] 我们的输入输出是什么，是采取自动生成还是人工生成，还是人机结合的方案
  a. 输入task,直接输出rubric
  b. 输入task,few-shot(rubrics),输出rubric
  c. 输入偏好对，输出rubric
  d. 输入粗糙的rubric，输出rubric
  e. 输入task,领域知识，输出rubric
  f. 输入少量专家标注的rubric,task，输出rubric generator
- [ ] Rubric生成过程需要考虑每一个item的权重吗?

Rubrics生成容易出现的问题：

1. 面对专业领域，直接利用LLM生成会因为行业壁垒导致Rubric过于简单，这种情况需要专业知识介入（人类专家或者领域知识库做RAG）

> `Learning to Judge` ： 医疗场景下效果不佳

Rubric生成/改写类型调研

主类别	子类别	核心思路	代表工作
全自动	LLM直接生成	从任务描述、prompt、样例直接生成 query-specific rubric	`Learning to Judge` `AdaRubric`
全自动	检索增强生成	先检索相似任务或领域 rubric，再生成当前 rubric	`RubricRAG`

全自动	偏好数据驱动生成	从 preference pairs 或 judge 数据里反推出显式 criteria	`Auto-Rubric`
全自动	Rubrics分解优化	把粗 rubric 改写成更细、更原子、更少冗余的 rubric	`RRD`
全自动	基于误差反馈做迭代 refinement	依据与人类分歧、评分误差、用户反馈来持续改写 rubric	`Reflect-and-Revise`，`iRULER`
纯人工	专家标注	利用人类专家为每一个task制定Rubrics	
人机结合	监督+偏好对齐生成	利用少量人类标注的Rubrics微调模型自动生成Rubrics	`SedarEval`

1. LLM直接生成

这类方法把 rubric generation 看成一个条件生成问题：输入任务描述、评分目标、少量样例，输出一组 criteria。

Learning to Judge: LLMs Designing and Applying Evaluation Rubrics

2. 检索/领域知识增强生成

这类方法认为，LLM 直接从任务描述生成 rubric 往往不够专业，因为缺少领域知识和历史经验；因此先检索相似任务或已有 rubric，再据此生成。

RubricRAG: Towards Interpretable and Reliable LLM Evaluation via Domain Knowledge Retrieval for Rubric Generation

3. 偏好数据驱动生成

这类方法不从任务描述直接编 rubric，而是从 preference pairs、奖励建模数据、judge 数据中“反推”什么 criteria 才是有效的。

Auto-Rubric: Learning to Extract Generalizable Criteria for Reward Modeling

4. Rubrics分解优化

这类方法不从零生成，而是假设你已经有一个粗糙 rubric，然后重点做 refinement：拆细、去重、纠偏、重加权。

Rethinking Rubric Generation for Improving LLM Judge and Reward Modeling for Open-ended Tasks

5. 基于误差反馈做迭代 refinement

这类方法更像“prompt optimization for rubric”。核心思想是：先拿一版 rubric 去打分，再看它和人类打分哪里不一致，然后据此改写 rubric。

Automated Refinement of Essay Scoring Rubrics for Language Models via Reflect-and-Revise

6. 专家标注

1. 专家根据任务目标、行业经验和常见错误模式，直接写出 rubric 条目、分值、描述和失败条件。

HealthBench: Evaluating Large Language Models Towards Improved Human Health OpenAI

2. 不是让单个专家写，而是通过 **Delphi / panel / consensus-building** 的方式，让多个专家逐步收敛。

成熟 rubric 系统最终都会带一个 codebook / scoring guide

Development of a rubric for assessing delayed diagnosis of appendicitis, diabetic ketoacidosis and sepsis

方法

- 针对 appendicitis、DKA、sepsis 三类诊断延误案例
- 组织多专科专家 Delphi panel
- 用多轮评分和理由反馈逐步收敛
- 以 **≥75% agreement** 作为共识标准
- 最终形成 case review guide / rubric

3. 在很多任务里，尤其是服务真实用户的任务，光让领域专家定义 rubric 不够，得同时引入多个角色

Measuring What Matters: Developing Human-Centered Legal Q-and-A Quality Standards through Multi-Stakeholder Research

这项工作不是只找律师，而是同时引入：法律专家，终端用户，技术人员。共同定义法律 AI 回答的质量标准。

7. 人机结合的Rubrics生成

这类方案直接利用专家标注一批Rubrics，然后利用这些标注好的Rubrics训练rubrics generator模型，最后利用rubrics generator批量打分。

SedarEval: Automated Evaluation using Self-Adaptive Rubrics。 小红书

Xpertbench: Expert Level Tasks with Rubrics-Based Evaluation。字节

一些其他关于Rubrics的规范

> **领域任务中，专家主要负责把“外部规范 + 隐性专业知识”转成 rubric；通用任务中，专家主要负责把“模糊偏好 + 群体分歧”转成结构化维度、锚点样例和可校准标准。**

所以：

- **领域任务** 更像 `标准映射 + 风险建模`
- **通用任务** 更像 `偏好显化 + 共识收敛 + 分歧管理`

领域任务设计Rubrics的规范

答案是：**通常存在，但层次不同。**

很多领域任务的 rubric 不是凭空写出来的，而是来自三层信息源：

硬规范（hard constraints）

包括：

- 法规
- 行业标准
- 模板
- 流程要求
- 合规要求
- 术语与格式规定

这些内容通常适合直接写成 rubric 中的硬约束。

半硬规范（semi-hard conventions）

包括：

- 行业通行写法
- 资深从业者默认遵循的结构
- 风险披露习惯
- 机构内部 style guide

这些通常不是法律硬要求，但专业场景里默认重要。

软判断（soft preferences）

包括：

- 是否更清晰
- 是否更稳妥
- 是否更便于客户/用户理解
- 风格是否专业

这些部分仍需要专家 judgment。

以“法律文书”举例：法律行业的基本规范

不同文书的规范来源不同。

对法院文书/裁判文书类任务

通常存在较强的制度性规范，比如：

- 文书结构
- 标题与案号
- 事实、理由、裁判依据、结论的组织方式
- 法条引用规范
- 隐私脱敏要求

例如中国法院体系中，就存在关于裁判文书制作规范、引用规范和样式模板的官方要求。

这意味着如果任务是“生成裁判文书样式文本”，rubric 里有一部分完全可以从规范直接映射出来。

对合同/规则/制度类起草任务

也存在较强的专业规范来源，比如：

- `A Manual of Style for Contract Drafting`
- `Essentials for Drafting Clear Legal Rules`
- plain language drafting principles
- 一致术语、定义使用、义务/权限表达规范

这种任务的 rubric 可以明确写：

- 是否存在歧义
- 是否定义术语
- 是否逻辑分层清楚
- 是否引用规范
- 是否风险分配明确

对法律问答/法律帮助任务

规范比“裁判文书”弱一些，但仍有明确的质量标准。

Stanford 的法律 AI rubric 工作就说明，法律问答的高质量标准至少包括：

- 正确性
- 可行动性
- 是否给出风险提示
- 是否帮助用户下一步行动

所以法律领域并不是“只有专家主观判断”，而是：

> **规范 + 风险控制 + 用户目标** 三者一起构成 rubric。

通用任务设计Rubrics的规范

> “生成一份作业 PPT，美观与否大家理解都不一样，专家无法得出共识，只能得出自己的主观判断，并且可能出现遗漏。”

因为通用任务常常同时具有三个特点：

没有外部权威标准

不像医疗、法律、财务那样有明确规范。

偏好存在群体差异

不同专家、不同老师、不同组织的偏好不一样。

好坏往往是多目标折中

例如 PPT：

- 更美观，可能牺牲信息密度
- 更完整，可能牺牲简洁度
- 更创意，可能牺牲统一性

所以这类任务里，一个更成熟的做法是：

- 不把 rubric 设计成“绝对答案”
- 而是设计成“多维、带锚点、可校准、允许一定分歧”的结构

`LLM-Rubric` 这类工作本质上就是在承认这一点：
连人类 judge 都不完全一致，因此系统不应假设存在单一无争议的总分。

通用任务里，专家通常**不是规范提供者**，而是以下几种角色：

把模糊偏好拆成稳定维度

比如 PPT“美观”不能直接评，但可以拆成：

- 视觉层级是否清晰
- 字体/颜色/版式是否一致
- 单页信息密度是否过高
- 图表是否易读
- 是否支持讲述逻辑

专家的作用，是把“审美直觉”拆成一组更稳定的 analytic dimensions。

提供 anchor examples

通用任务里，最有效的往往不是抽象定义，而是：

- 什么叫 4 分样例
- 什么叫 2 分样例
- 为什么这个样例好
- 差距在哪里

这比“美观、专业、整洁”这类抽象词更可靠。

暴露分歧，而不是假装没有分歧

在开放任务里，不同专家可能偏好不同：

- 有的人更重视觉统一
- 有的人更重信息清晰
- 有的人更重叙事逻辑

这时更合理的方法不是强行统一，而是：

- 先记录分歧
- 区分高共识维度与低共识维度
- 对低共识维度降低权重或允许 judge-specific calibration

发现遗漏维度

即便专家主观，也仍然比模型更容易发现：

- rubric 忘记评价可读性
- 忘记评价叙事结构
- 忘记评价信息完整性
- 只写了审美，没有写功能性

所以专家对通用任务最大的作用之一，其实是**补漏**。

如何对生成的Rubrics做评估

1. 文本/结构层

看 rubric 本身写得怎么样。

常见指标：

- 与 human-authored rubric 的相似度
- 对人工 rubric 的覆盖率
- criterion 数量
- uniqueness / redundancy
- atomicity
- hierarchy 是否清晰

对应工作：

- `Learning to Judge, RubricRAG, RRD`

2. 下游判分层

看 rubric 是否真的让 judge 变强。

常见指标：

- preference accuracy
- human agreement
- correlation / QWK / Spearman
- RewardBench / JudgeBench / PPE 表现
- 在 pairwise comparison 上的胜率

对应工作：

- `Auto-Rubric, RRD, Reflect-and-Revise, RubricBench`

3. 稳定性/鲁棒性层

看 rubric 是否稳定可靠。

常见指标：

- prompting condition 变化下的一致性
- cross-model transfer
- leniency / strictness
- surface bias 是否减少

对应工作：

- `Learning to Judge, RubricBench`

4. 人类使用价值层

看 rubric 是否真的方便人理解、使用、修订。

常见指标：

- user helpfulness
- alignment with user criteria
- intelligibility
- revision quality

对应工作：

- `iRULER, RubricRAG`